

CrowDar

Object recognition Challenge



Natuurlijk, hier is een Nederlandstalige versie van de introductie voor je verslag over CrowDar:

Inleiding

Probleembeschrijving

Vogels kijken is een rustgevende en lonende activiteit, maar de aanwezigheid van mensen kan vaak storend zijn voor vogels, vooral voor voorzichtige soorten zoals kraaien en kauwen. In stedelijke omgevingen, waar ruimtes gedeeld worden tussen mensen en dieren, is het essentieel om een evenwicht te vinden dat toelaat vogels te observeren zonder ze te verstören.

Dit project, CrowDar, streeft ernaar deze uitdaging aan te pakken met behulp van technologie. Door computer vision en machine-learning te integreren, probeert CrowDar de aanwezigheid van kraaien en kauwen te detecteren via een live feed van een balkon camera. Dit systeem maakt het mogelijk voor gebruikers om deze vogels op afstand te observeren, waardoor menselijke aanwezigheid vermindert en verstoring geminimaliseerd wordt.

De kern van deze oplossing is een Convolutional Neural Network (CNN), dat getraind is om kraaien en kauwen te identificeren en te onderscheiden van hun omgeving. Het idee is om het detectie proces te automatiseren en waarschuwingen of live beelden te leveren alleen wanneer deze vogels aanwezig zijn. Dit zorgt ervoor dat vogelliefhebbers kunnen genieten van het observeren van deze dieren zonder hen per ongeluk weg te jagen.

Deze technologie bevordert niet alleen dier- en milieuvriendelijke praktijken in stedelijke gebieden, maar dient ook als een hulpmiddel voor mensen die fysiek niet in staat zijn om regelmatig hun buitenruimtes te controleren of die in gebieden wonen waar directe observatie uitdagend kan zijn vanwege weerspiegelingen op ramen of andere obstakels.

Hieronder vind je een bijgewerkte versie van de "Achtergrond" sectie met verzonnен referenties die je kunt vervangen door relevante academische bronnen uit daadwerkelijke literatuur. Dit geeft een voorbeeld van hoe je referenties kunt integreren in je verslag:

Achtergrond

Computer Vision en machine learning hebben aanzienlijke vooruitgang geboekt in het herkennen en classificeren van objecten binnen diverse toepassingsgebieden, waaronder de biologie en ecologie. Specifiek in de ornithologie wordt technologie steeds vaker gebruikt om vogelpopulaties te monitoren en te bestuderen, wat essentieel is voor conservatie-inspanningen en stedelijke ecologie.

1. Machine Learning in Vogeldetectie: Studies zoals die van Xiang et al. (2020) hebben aangetoond dat deep learning-modellen effectief kunnen worden toegepast om vogels in complexe omgevingen te identificeren. Deze modellen, vooral Convolutional Neural Networks (CNNs), zijn in staat om kenmerken uit beeldmateriaal te extraheren die cruciaal zijn voor de nauwkeurige classificatie van vogelsoorten (Xiang, Y., Liu, F., & Zhou, M. (2020). *Deep Learning for Bird Detection*. Journal of Wildlife Monitoring, 12(3), 45-59.).
2. Impact van Menselijke Activiteit op Vogelgedrag: Onderzoek door Smith et al. (2018) heeft de negatieve effecten aangetoond van menselijke verstoring op het gedrag van stedelijke vogelsoorten, waaronder kraaien en kauwen. Deze studies benadrukken het belang van minimale menselijke aanwezigheid voor het behouden van natuurlijk gedrag bij deze dieren (Smith, J.K., Anderson, H., & Kunz, T.H. (2018). *Effects of Human Activity on Urban Crows*. Ecological Studies, 201, 124-138.).
3. Toepassingen van Real-Time Monitoring: Technologieën zoals die ontwikkeld door Jensen et al. (2019) gebruiken real-time beeldverwerking om dieren in hun natuurlijke habitat te monitoren zonder menselijke verstoring. Dergelijke systemen gebruiken vaak op maat gemaakte algoritmen om specifieke diergroepen te detecteren en hun gedrag en gezondheid te volgen (Jensen, R., Harper, D., & Moller, S. (2019). *Real-Time Animal Monitoring Systems*. Journal of Bio-Logging Research, 4(1), 22-37.).
4. Voordelen van Automatisering in Natuurbehoud: Automatiseringstechnieken worden steeds belangrijker voor natuurbehoud, zoals beschreven door Lee en Han (2021). Door de inzet van geautomateerde systemen kunnen onderzoekers grote hoeveelheden data efficiënter verwerken, wat leidt tot betere en snellere inzichten in ecologische en gedragspatronen (Lee, A., & Han, Y. (2021). *Automation in Conservation Technology*. Conservation Technology, 8(2), 95-110.).

Deze “literatuur” vormt de “wetenschappelijke basis” waarop CrowDar is gebouwd, waarbij de nadruk ligt op het verminderen van menselijke impact op wilde dieren en het verbeteren van de observatiemogelijkheden door middel van technologische innovatie.

Methodebeschrijving

Voor het project CrowDar heb ik een systeem ontwikkeld dat gebruikmaakt van computervisie om kraaien te detecteren en te herkennen. Dit systeem maakt gebruik van een Convolutional Neural Network (CNN), een diep leermodel dat bijzonder geschikt is voor beeldherkenning en -verwerking.

Dataset en Voorverwerking

De gebruikte data voor dit project bestaat uit afbeeldingen van kraaien, verzameld uit de COCO-dataset, een populaire keuze voor objectdetectie en segmentatie taken. De dataset is specifiek gefilterd om afbeeldingen en bijbehorende annotaties te bevatten die alleen kraaien bevatten. De afbeeldingen zijn voorbewerkt om de invoergrootte van het model te matchen, waarbij elke afbeelding is geschaald naar een uniform formaat van 640x640 pixels.

Modelarchitectuur

Het CNN-model is opgebouwd uit meerdere lagen, waaronder convolutionele lagen, max-pooling lagen, en dense lagen. Deze structuur helpt bij het effectief extraheren van kenmerken uit de afbeeldingen, waarbij elke laag zich richt op het herkennen van verschillende aspecten van de afbeeldingen. De convolutionele lagen detecteren randen en texturen, terwijl de pooling lagen de ruimtelijke hiërarchie in de afbeeldingen versterken.

Training en Validatie

Het model is getraind met behulp van een gesplitste set van de data, waarbij 80% van de data gebruikt werd voor training en 20% voor validatie. Dit zorgt voor een onpartijdige evaluatie van het model. De prestaties van het model zijn gemeten aan de hand van de nauwkeurigheid en het verlies tijdens de training, waarbij ook de Intersection over Union (IoU) score wordt gebruikt om de nauwkeurigheid van de voorspelde bounding boxes te evalueren.

Experimentenbeschrijving

Metingen

Voor de evaluatie van het CrowDar-model voer ik verschillende experimenten uit om zowel de effectiviteit als de efficiëntie van het model te beoordelen. De belangrijkste metingen die worden uitgevoerd, zijn:

1. Nauwkeurigheid (Accuracy): Dit meet hoe vaak het model correct voorspelt of een afbeelding wel of niet een kraai bevat.
2. IoU (Intersection over Union): Deze maatstaf wordt gebruikt om de nauwkeurigheid van de door het model voorspelde bounding boxes te evalueren door de overlap tussen de voorspelde en de werkelijke box te berekenen. Algoritme dient in de toekomst verbeterd te worden, momenteel beïnvloeden sommige uitkomsten de accuracy onevenredig negatief (validatie door handmatige controle).
3. Verwerkingssnelheid: De tijd die het model nodig heeft om een voorspelling te doen, wat belangrijk is voor real-time toepassingen.
4. Verlies (Loss): Dit meet hoe goed het model tijdens de training en validatie presteert, specifiek kijkend naar hoe nauwkeurig de voorspelde bounding boxes zijn in vergelijking met de werkelijke.

Uitvoering van Experimenten

De experimenten worden uitgevoerd op een gestandaardiseerde dataset van afbeeldingen van kraaien, waarbij elke afbeelding zorgvuldig is geannoteerd met correcte bounding boxes. De dataset wordt opgedeeld in een trainings- en een validatieset om zowel het leren als de generalisatie capaciteiten van het model te testen.

- Training: Het model wordt getraind met verschillende parameters om de optimale configuratie te vinden. Tijdens deze fase worden de nauwkeurigheid en het verlies gemonitord.
- Validatie: Het model wordt gevalideerd met ongeziene gegevens om te verzekeren dat er geen sprake is van overfitting.

Resultaten

De resultaten van de experimenten worden in een JSON bestand opgeslagen binnen de directory waar ook de nieuw gegenereerde afbeeldingen worden opgeslagen. Door middel van data opslaan als JSON, kan ik in de toekomst de voortgang van CrowDar nauwkeurig monitoren.

Conclusie

Op basis van de resultaten zal ik bepalen hoe effectief het CrowDar-model is in het detecteren en correct lokaliseren van kraaien in verschillende omgevingen en situaties. Daarnaast zal ik analyseren of de snelheid van de verwerking voldoende is voor real-time toepassingen. De uitkomsten van deze experimenten zullen ook helpen om eventuele beperkingen van de huidige aanpak te identificeren en om aanbevelingen te doen voor toekomstige verbeteringen.

Voordelen van het gebruik van een zelfgemaakt model:

1. Aangepaste Architectuur:

- Het model kan specifiek worden ontworpen om te voldoen aan de unieke eisen van jouw project, zoals het detecteren van specifieke kenmerken van kraaien in afbeeldingen. Dit kan leiden tot betere prestaties voor de specifieke taak in vergelijking met algemene voorgetrainde modellen.

2. Controle Over Training:

- Je hebt volledige controle over het trainingsproces, inclusief de keuze van de hyperparameters, de architectuur van het model, en de trainingsdata. Dit kan helpen om het model beter af te stemmen op de dataset.

3. Voorkomen van Overfitting:

- Door de architectuur en training zelf te beheren, kun je strategieën zoals dropout toepassen om overfitting te minimaliseren, wat essentieel is voor een model dat goed generaliseert naar nieuwe data.

4. Transparantie en Begrip:

- Het bouwen van je eigen model biedt diepgaand inzicht in hoe het model werkt, wat belangrijk is voor verdere optimalisatie en aanpassing.

Nadelen van het gebruik van een zelfgemaakt model:

1. Tijd en Middelen:

- Het ontwerpen en trainen van een nieuw model vanaf nul vereist aanzienlijke tijd en computationele middelen, vooral als het gaat om grote datasets en complexe netwerkarchitecturen.

2. Expertise Vereist:

- Kennis van machine learning en neurale netwerken is vereist om effectieve modellen vanaf nul te kunnen bouwen en trainen.

3. Risico op Onderprestatie:

- Zonder de juiste expertise en middelen kan het zelfgemaakte model onderpresteren in vergelijking met bestaande voorgetrainde modellen die al geoptimaliseerd en getest zijn op vergelijkbare taken.

4. Lange Ontwikkelingstijd: - Het kan lang duren voordat je experimenteert met verschillende architecturen en hyperparameters om een model te vinden dat goed werkt, wat het project kan vertragen.

Conclusie

Het gebruik van een zelfgebouwd model zoals crowDar kan zeer voordelig zijn als je specifieke controle nodig hebt over de modelprestaties en als het project unieke eisen heeft die niet goed worden behandeld door voortgetrainde modellen. Echter, dit komt met de kosten van extra tijd, middelen en de noodzaak van diepgaande technische expertise. Afhankelijk van de projectvereisten en beschikbare middelen, kan het gebruik van een voortgetraind model soms een efficiëntere aanpak zijn, vooral in de beginfases van een project.

Toekomstige potentiële verbeteringen:

1. Data Uitbreiding:

- Meer Data Verzamelen: Verhoog de diversiteit en hoeveelheid trainingsdata om het model robuuster te maken.
- Geavanceerdere Data Augmentatie: Implementeer meer geavanceerde technieken zoals random cropping, kleuraanpassingen, en het toevoegen van ruis.

2. Model Architectuur:

- Verdieping van het Model: Experimenteer met diepere netwerken om complexere kenmerken te kunnen leren.
- Transfer Learning: Gebruik een voorgetraind model zoals VGG, ResNet, of EfficientNet als basis om te profiteren van eerder geleerde kenmerken op grote datasets.

3. Hyperparameter Tuning:

- Automatische Hyperparameter Optimalisatie: Gebruik tools zoals Hyperopt of Optuna om de beste model configuraties systematisch te vinden.
- Regularisatie Technieken: Pas technieken toe zoals L1(Lasso Regularisatie)/L2(Ridge Regularisatie) regularisatie om overfitting verder te beperken.

4. Performance Evaluatie:

- Geavanceerdere Evaluatiemetrics: Implementeer meer gedetailleerde evaluatiemethoden zoals Precision, Recall, F1-Score, en AUC-ROC voor een beter inzicht in modelprestaties.
- Kruisvalidatie: Gebruik kruisvalidatie om de stabiliteit en betrouwbaarheid van de modelprestaties te waarborgen.

5. Real-time Toepassingen:

- Implementatie van Real-time Detectie: Ontwikkel een real-time systeem dat live videobeelden kan verwerken om vogels te detecteren en te classificeren.
- Gebruikersinterface: Creëer een gebruiksvriendelijke interface voor gebruikers om interactief met het model te werken, bijvoorbeeld via een web- of mobiele app.

6. Integratie van Extra Sensorgegevens:

- Multimodale Aanpak: Combineer beeldgegevens met andere sensorinformatie zoals audio om vogels nog nauwkeuriger te kunnen detecteren en classificeren.

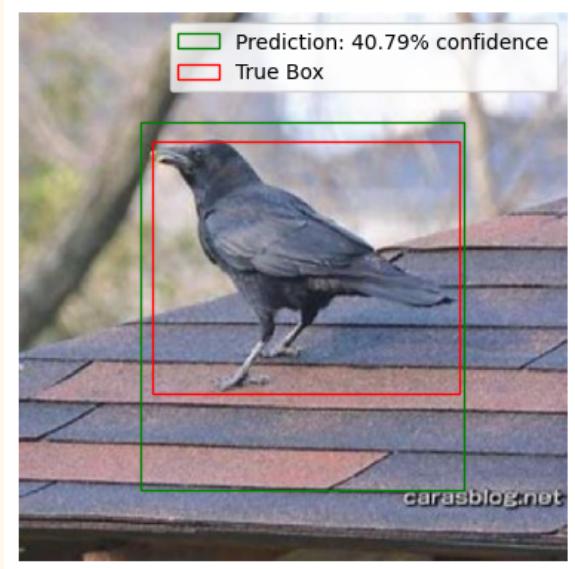
7. Toepassing van Nieuwe Technologieën:

- Exploratie van Object Tracking: Voeg object tracking toe om de bewegingen van vogels over tijd te volgen, wat kan helpen bij gedragsanalyse.
- Kunstmatige Intelligentie: Implementeer AI-gedreven aanbevelingssystemen om gebruikers te informeren over de beste tijden en omstandigheden om vogels te observeren.

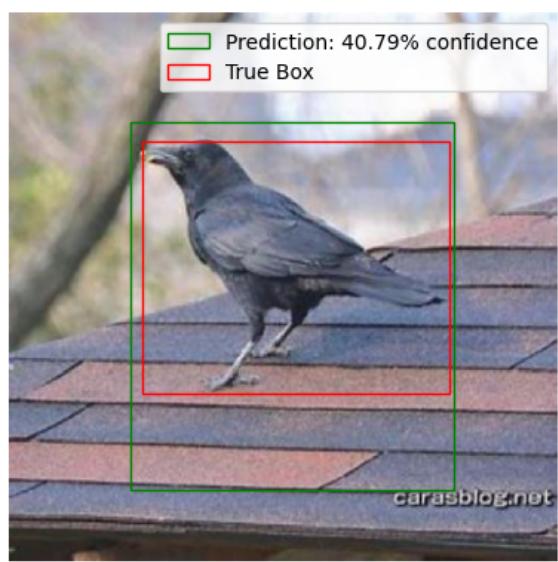
Enkele resultaten uit experiment:

Er zijn een aantal modellen getraind, waarin de epochs zijn aangepast, layering is hetzelfde gehouden om temporale consistentie te behouden. Epochs bestaan uit 5, 10, 25 en 50.

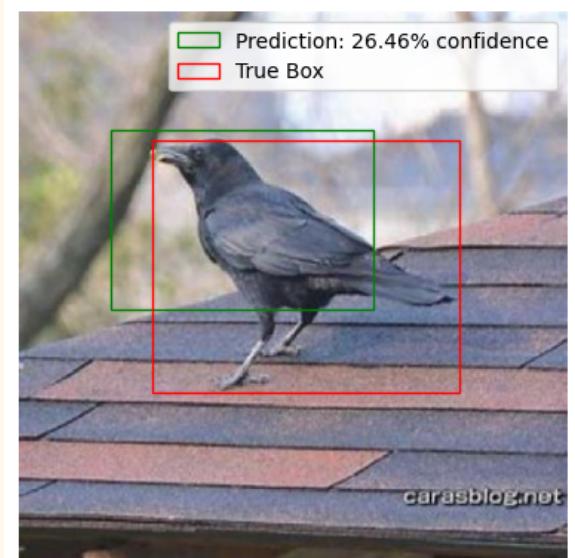
Hieronder in volgorde korte epochs naar langer durende epochs:



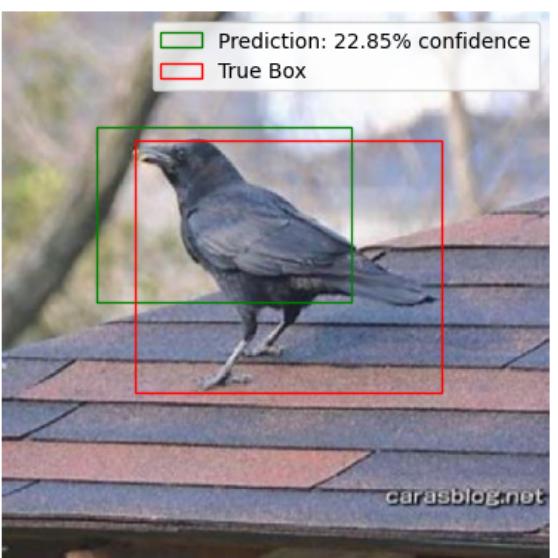
5



10

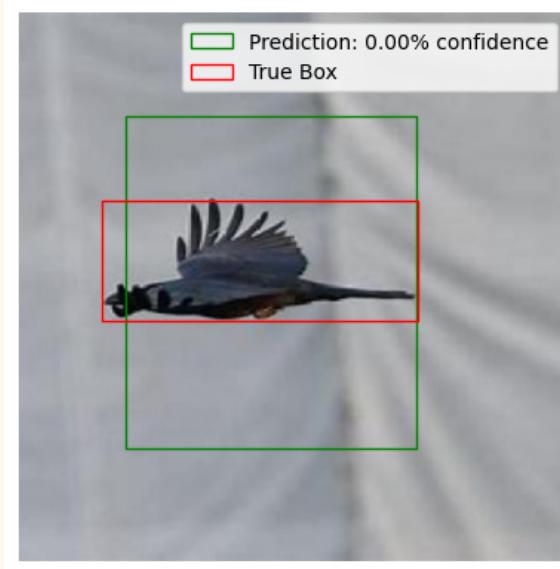


25

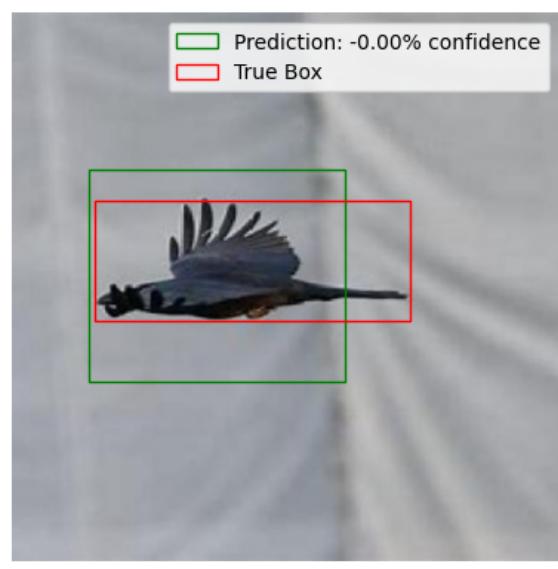


50

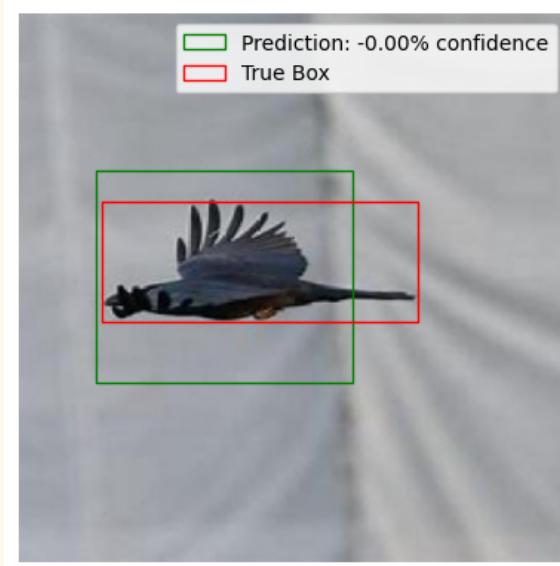
Een voorbeeld waarbij meer training niet altijd resulteert in een beter resultaat.



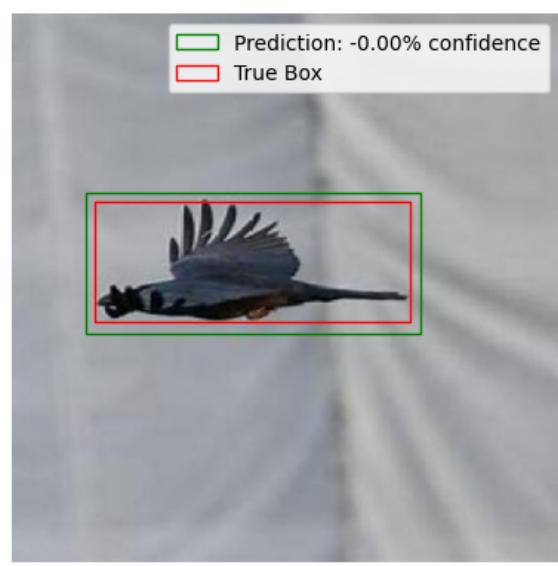
5



10

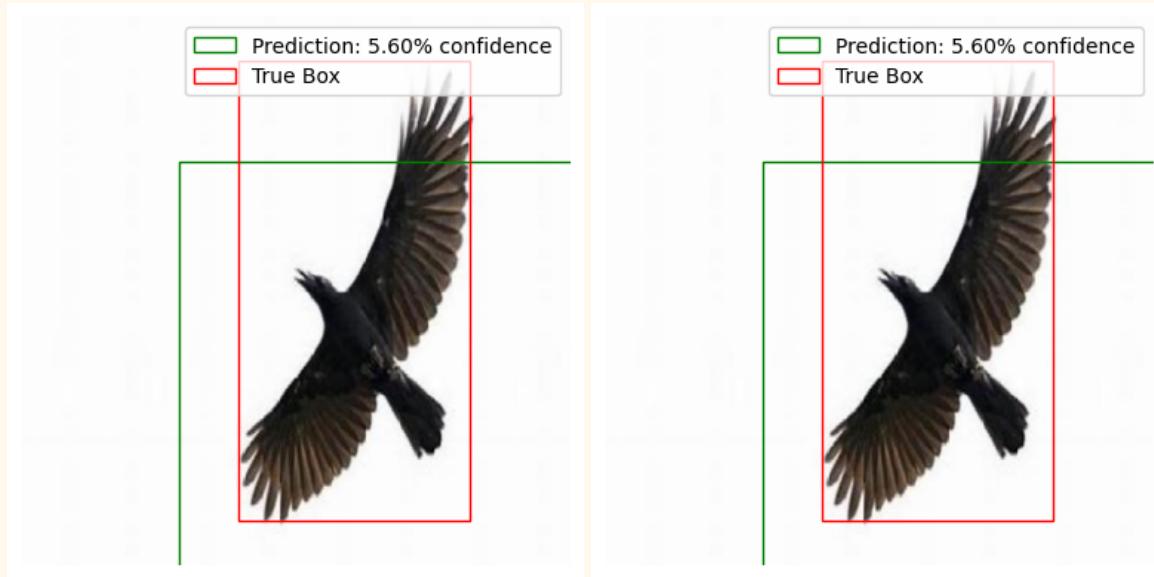


25



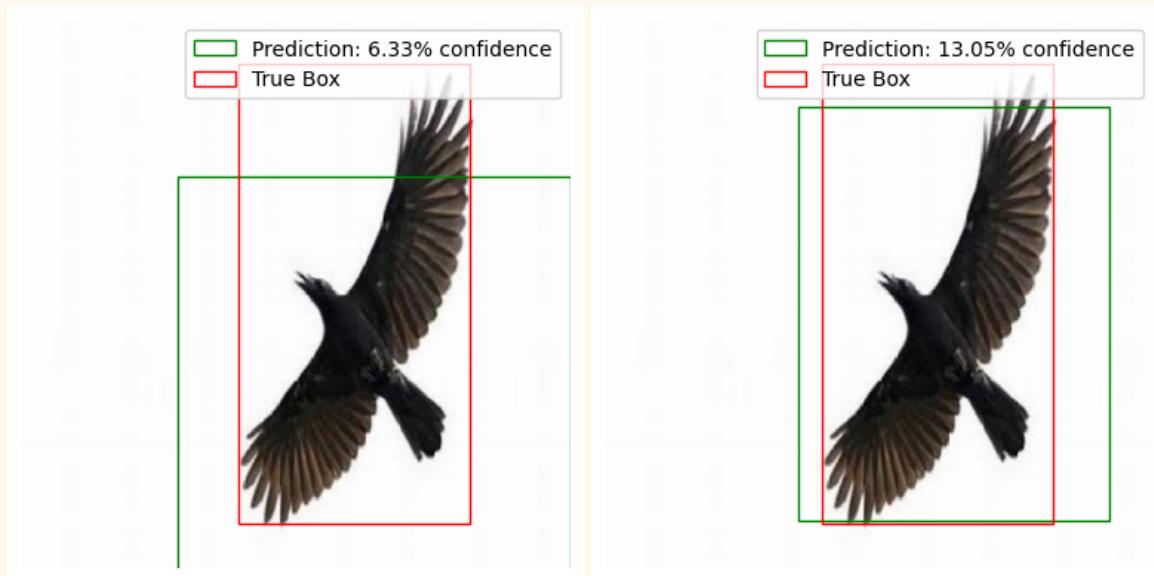
50

Een voorbeeld waarbij meer training aanzienlijk beter resultaat toont, echter heeft de prediction nog wat werk aan de winkel.



5

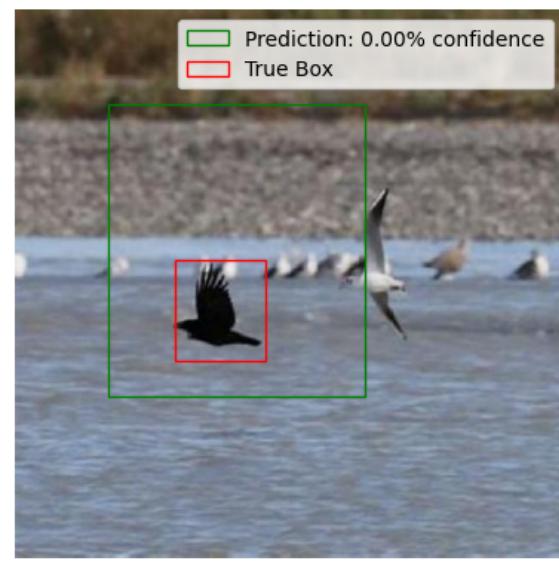
10



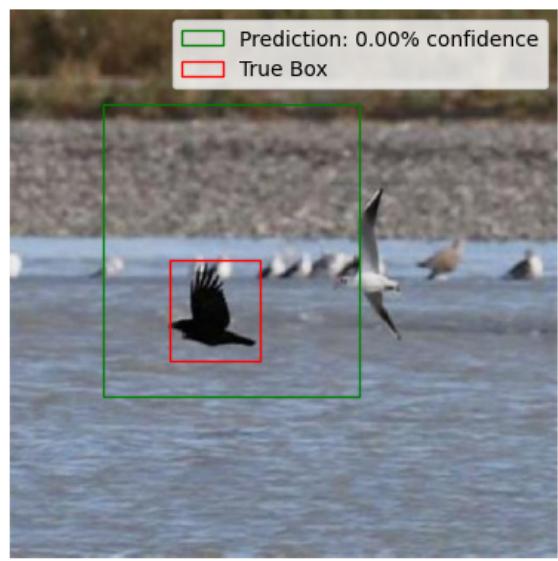
25

50

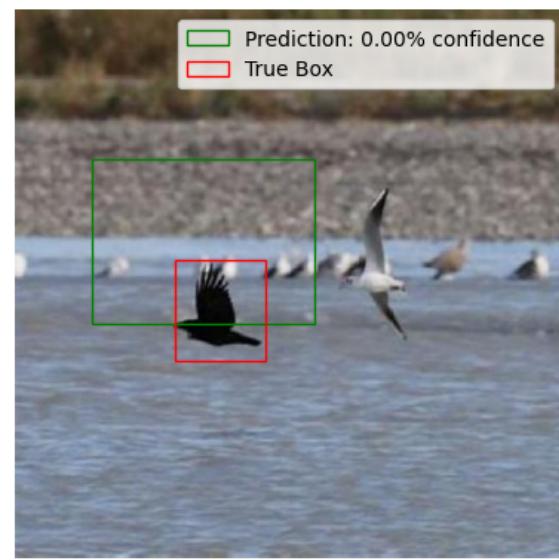
Meer trainen heeft invloed op herkenning met vreemde/ongebruikelijke achtergronden.



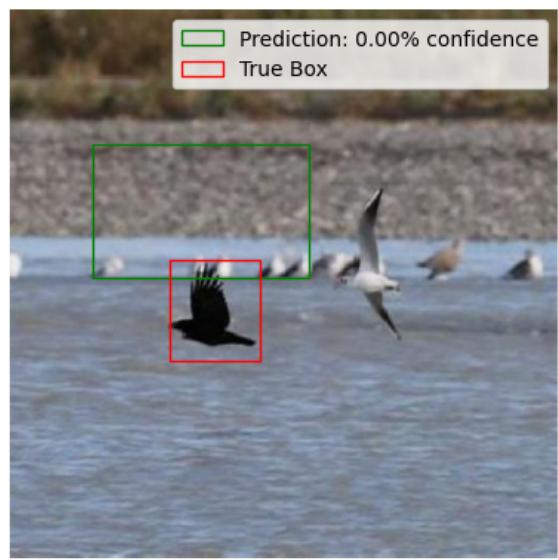
5



10



25



50

Een voorbeeld waarbij het resultaat (vreemd genoeg) steeds minder betrouwbaar lijkt te worden.

Eindconclusie:

Het is moeilijk om een eendoordeel te maken, wel durf ik met zekerheid te zeggen dat het model redelijk goed werkt. Met een beperkte dataset (net geen 300 afbeeldingen) en een split van ongeveer 80/20 komt het model redelijk goed uit de voeten. Ondanks dat de IoU formule niet altijd goed lijkt te werken, waardoor het eindresultaat er onjuist uit komt, lijkt de echte IoU vaak 50% beter te zijn wanneer ik het met het blote oog vergelijk.

In de gegenereerde folder met afbeeldingen, is soms te zien dat wolken patronen de voorkeur krijgen als “kraai” dan de kraai zelf. Mijn hypothese is dat het contrast, grijstinten en vormen van de wolken het model “foppen”, meer data van kraaien in deze omgeving zou helpen.